DUT ID.
Année 2025-2026.
Matière : BIG DATA
Enseignant : A. BOUIGADERN

المدرسة العليا للتكنولوجيا - كلميم
ⵜⴰⵙⴷⴰⵡⵉⵜ ⵜⴰⵏⴰⵎⵓⵔⵜ ⵏ ⵜⴰⵣⵅⵏⴰⵏⵜ - ⴳⵍⵎⵉⵎ
ÉCOLE SUPÉRIEURE DE TECHNOLOGIE - GUELMIM

Travaux Pratiques N°4 :Big Data

Analyse du Dataset Students Performance (avec tableaux)

Dataset Kaggle : https://www.kaggle.com/datasets/spscientist/students-performance-in-exams
Fichier : *StudentsPerformance.csv*
Taille : 1000 lignes

Recopiez chaque bloc de code puis analysez les résultats en les interprétant et en commentant les tableaux et les valeurs affichées.

Pré-requis techniques

Installer PySpark (version stable)

```
pip install pyspark==3.5.1
```

Vérifier Java 11

```
java -verion
```

Mettre *StudentsPerformance.csv* dans le même dossier que ton Notebook.

Initialisation Spark dans Jupyter

Cellule 1 — Configuration Java

```
import os

os.environ["JAVA_HOME"] = r"C:\Program Files\Eclipse Adoptium\jdk-11.0.29+7"
os.environ.pop("SPARK_HOME", None)

print("JAVA_HOME =", os.environ.get("JAVA_HOME"))
print("SPARK_HOME =", os.environ.get("SPARK_HOME"))
```

Cellule 2 — Création du SparkSession

```
[*]: import pyspark
     from pyspark.sql import SparkSession

     print("PySpark version:", pyspark.__version__)

     spark = (SparkSession.builder
              .appName("TP_Students")
              .master("local[2]")
              .config("spark.ui.enabled", "false")
              .getOrCreate())

     spark
```

Chargement du Dataset

```
df = spark.read.csv(
     "StudentsPerformance.csv",
     header=True,
     inferSchema=True
)

df.show(5)
df.printSchema()
print("Nombre de lignes :", df.count())
```

Afficher les données en tableau propre (Pandas)

```
df.toPandas().head(10)
```

Affiche un **tableau HTML lisible** dans Jupyter.

Exploration rapide

```
df.describe().toPandas()
```

Tableau avec moyenne, min, max, écart-type.

Nettoyage

Le dataset est propre, mais on applique une règle stricte pour le TP :
supprimer les lignes contenant des valeurs nulles.

```
df_clean = df.na.drop()
print("Après nettoyage :", df_clean.count())
```

Créer une colonne : moyenne générale

```
: from pyspark.sql.functions import col

  df2 = df_clean.withColumn(
      "average_score",
      (col("math score") + col("reading score") + col("writing score")) / 3
  )

  df2.toPandas().head(10)
```

Analyses principales

1. Moyenne des notes par genre

```
result_gender = (df2.groupBy("gender")
    .avg("math score", "reading score", "writing score", "average_score")
    .toPandas())

result_gender
```

2. Moyenne générale par type de repas

```
result_lunch = (df2.groupBy("lunch")
    .avg("average_score")
    .orderBy("avg(average_score)", ascending=False)
    .toPandas())
```

```
result_lunch
```

3. Score selon l'éducation des parents

```
result_parent = (df2.groupBy("parental level of education")
    .avg("average_score")
    .orderBy("avg(average_score)", ascending=False)
    .toPandas())
```

```
result_parent
```

Spark SQL

Créer la vue :

```
df2.createOrReplaceTempView("students")
```

1) Top 10 meilleurs élèves

```
spark.sql("""
SELECT gender, `math score`, `reading score`, `writing score`, average_score
FROM students
ORDER BY average_score DESC
LIMIT 10
""").toPandas()
```

2) Score moyen par groupe ethnique

```
spark.sql("""
SELECT `race/ethnicity`, AVG(average_score) AS avg_score
FROM students
GROUP BY `race/ethnicity`
ORDER BY avg_score DESC
""").toPandas()
```

3) Impact du cours de préparation

```
spark.sql("""
SELECT `test preparation course`, AVG(average_score) AS avg_score
FROM students
GROUP BY `test preparation course`
""").toPandas()
```

Bonus : Ajouter une colonne “success / fail”

```
from pyspark.sql.functions import when

df3 = df2.withColumn(
    "success",
    when(col("average_score") >= 70, "success").otherwise("fail")
)

df3.groupBy("success").count().toPandas()
```

Résultats attendus :

- Créer un SparkSession
- Charger un CSV
- Afficher les données sous forme de tableau lisible
- Nettoyer les données
- Ajouter des colonnes dérivées
- Analyser avec groupBy
- Faire des requêtes SQL
- Utiliser Pandas pour visualiser les résultats